

Business Analytics

1장, 2장. 데이터 마이닝 프로세스 개요 - West Roxbury 데이터셋을 활용

```
# Loading data
housing.df <- read.csv('https://raw.githubusercontent.com/reisanar/datasets/master/WestRoxbury.csv')
dim(housing.df)
```

```
## [1] 5802 14
```

```
# Random sample of 5 observations
housing.df[sample(row.names(housing.df), 5), ]
```

```
##      TOTAL.VALUE  TAX LOT.SQFT YR.BUILT GROSS.AREA LIVING.AREA FLOORS ROOMS
## 925          290.0 3648      5304    1960      2576      1288    1.0    5
## 3557         371.9 4678      7515    1960      2388      1265    1.5    6
## 2703         468.6 5894     10542    1900      2820      1719    2.0    8
## 5527         589.6 7417      5701    1947      3968      2496    2.0    9
## 729          266.6 3353      2835    1984      2464      1596    2.0    6
##      BEDROOMS FULL.BATH HALF.BATH KITCHEN FIREPLACE REMODEL
## 925           3         1         1         1         1    None
## 3557           3         2         0         1         1    None
## 2703           4         1         1         1         1    None
## 5527           4         2         1         1         2 Recent
## 729           3         1         1         1         1    None
```

```
# Oversample houses with over 10 rooms
s <- sample(row.names(housing.df), 5, prob = ifelse(housing.df$ROOMS > 10, 0.9, 0.01))
housing.df[s, ]
```

```
##      TOTAL.VALUE  TAX LOT.SQFT YR.BUILT GROSS.AREA LIVING.AREA FLOORS ROOMS
## 4310          363.8 4576      3917    1928      2491      1268    1.5    6
## 2789          505.3 6356     10000    1890      4458      2762    2.0   12
## 5688          379.8 4777      5000    1930      2050      1274    2.0    6
## 3458          689.3 8671      7000    1848      6235      3446    2.0   12
## 4860          463.2 5827      5846    1935      2652      1752    2.0    7
##      BEDROOMS FULL.BATH HALF.BATH KITCHEN FIREPLACE REMODEL
## 4310           3         1         1         1         1    None
## 2789           6         2         1         1         0 Recent
## 5688           3         1         1         1         1    None
## 3458           5         3         0         1         2    None
## 4860           3         1         0         1         1    None
```

분류하고자 하는 데이터가 희귀할 경우에는 이를 처리할 수 있도록 해줘야 한다.

이를 하는 방법은 소수 사건에 가중치를 부여하거나, 오분류에 큰 가중치를 주는 방법이 있다.

```
# Categorical variables -> Dummy variables
xtotal <- model.matrix(~ 0 + BEDROOMS + REMODEL, data = housing.df)
xtotal <- as.data.frame(xtotal)
t(t(names(xtotal)))
```

```
##      [,1]
## [1,] "BEDROOMS"
## [2,] "REMODELNone"
## [3,] "REMODELOld"
## [4,] "REMODELRecent"
```

```
xtotal <- xtotal[, -4]
head(xtotal, 5)
```

```
##  BEDROOMS REMODELNone REMODELOld
## 1         3           1           0
## 2         4           0           0
## 3         4           1           0
## 4         5           1           0
## 5         3           1           0
```

범주의 순서가 없는 Categorical variables의 값들은 가변수를 만들어주는 Dummy coding이 가능하다.

```
# Median 값으로 결측치 대체하기
rows.to.missing <- sample(row.names(housing.df), 10)
housing.df[rows.to.missing, ]$BEDROOMS <- NA
summary(housing.df$BEDROOMS)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
##      1.00   3.00   3.00   3.23   4.00   9.00     10
```

```
housing.df[rows.to.missing, ]$BEDROOMS <- median(housing.df$BEDROOMS, na.rm = TRUE)
summary(housing.df$BEDROOMS)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.000   3.000   3.000   3.229   4.000   9.000
```

```
set.seed(1)
```

```
# Train, valid dataset split
train.rows <- sample(rownames(housing.df), dim(housing.df)[1] * 0.6)
train.data <- housing.df[train.rows, ]
valid.rows <- setdiff(rownames(housing.df), train.rows)
valid.data <- housing.df[valid.rows, ]

# Train, valid, test = 50%, 30%, 20%
train.rows <- sample(rownames(housing.df), dim(housing.df)[1] * 0.5)
valid.rows <- sample(setdiff(rownames(housing.df), train.rows),
                    dim(housing.df)[1] * 0.3)
test.rows <- setdiff(rownames(housing.df), union(train.rows, valid.rows))
```

```
train.data <- housing.df[train.rows, ]
valid.data <- housing.df[valid.rows, ]
test.data <- housing.df[test.rows, ]
```

```
dim(train.data)
```

```
## [1] 2901 14
```

```
dim(valid.data)
```

```
## [1] 1740 14
```

```
dim(test.data)
```

```
## [1] 1161 14
```

모델을 구축하기 위해서 데이터셋을 Train, Valid, Test로 나눠주도록 한다.

일반적으로 모델링 과정은 다음과 같은 순서를 갖는다.

데이터 마이닝 모델링 process

1. [목적] 웨스트 록스베리 지역 주택 가격을 예측한다.
2. [데이터 획득] 주택 가격 데이터를 활용한다.
3. [데이터 탐색, 정제, 전처리] 변수에 대한 충분한 이해를 한다.
 - 어떤 변수를 사용할 것인가
 - 이상치 유무를 확인
 - 범주형 변수를 가변수로 변환 (Dummy coding)
4. [차원 축소] 많은 변수를 갖는 경우에는, 차원 축소 방법을 사용한다.
5. [데이터 마이닝 태스크 결정] 주택 가격 예측을 위한 지도학습 방법을 사용한다.
6. [지도학습을 위해 데이터 분할] Train, Valid, Test 데이터로 나눈다.
7. [데이터 마이닝 기법 선택] 이번 분석에서는 다중회귀분석을 사용한다.
8. [태스크를 위한 알고리즘 사용] 모델 평가 지표를 만든다.
9. [결과 해석] 다양한 방법을 통해 나온 결과들 중 가장 좋은 모델을 선택한다.
10. [모델 사용] 최상의 모델에 대해서 목표한 바에 대한 결과를 얻는다.

Modeling

```
reg <- lm(TOTAL.VALUE ~ ., data = housing.df, subset = train.rows)
tr.res <- data.frame(train.data$TOTAL.VALUE, reg$fitted.values, reg$residuals)
head(tr.res)
```

```
##      train.data.TOTAL.VALUE reg.fitted.values reg.residuals
## 1886                356.7          356.7175    -0.01745989
## 3515                333.3          333.2673     0.03267493
## 460                 298.6          298.6111    -0.01111445
## 855                 265.3          265.3050    -0.00503505
## 4094                575.1          575.0797     0.02026379
## 3581                348.0          347.9750     0.02502157
```

```
# 만들어진 모델을 Valid 데이터에 적용하기
```

```
pred <- predict(reg, newdata = valid.data)
vl.res <- data.frame(valid.data$TOTAL.VALUE, pred,
                     residuals = valid.data$TOTAL.VALUE - pred)
head(vl.res)
```

```
##      valid.data.TOTAL.VALUE      pred      residuals
## 5642                318.0 318.0047 -0.0046799114
## 2766                498.7 498.6882  0.0118467844
## 3676                331.8 331.8371 -0.0370594670
## 2054                371.9 371.8998  0.0002217257
## 2217                436.2 436.2079 -0.0078569690
## 3117                280.2 280.1660  0.0340387189
```

```
# 모델의 평가 측도를 계산
```

```
accuracy(reg$fitted.values, train.data$TOTAL.VALUE) # train data
```

```
##              ME          RMSE          MAE          MPE          MAPE
## Test set -3.42853e-17 0.02273201 0.01969155 2.691985e-06 0.005303514
```

```
pred <- predict(reg, newdata = valid.data)
accuracy(pred, valid.data$TOTAL.VALUE)
```

```
##              ME          RMSE          MAE          MPE          MAPE
## Test set -0.0001632785 0.02300847 0.01984785 -9.496239e-05 0.005331516
```

5장. 예측 성능 평가

지도 학습의 출력 변수

1. 예측된 수치값: 출력 변수가 주택 가격과 같은 수치값
2. 예측된 클래스 소속도: 출력 변수가 범주값
 - 경향의 컷오프(Threshold) 값을 사용하여 클래스 소속도 생성
3. 경향: 출력 변수가 범주값 일 때의 클래스 소속도의 확률